

1 Distributions

Binominale Distribution mit zurücklegen

⚠️ Mit zurücklegen ⚠️

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Beispiel: Wir haben 7 Weiße Bälle und 3 Rote Bälle: Wie groß ist die Wahrscheinlichkeit, dass wir in $n=5$ Zügen $k=2$ rote Bälle ziehen? p ist $7/10$

$$P(X = 2) = \binom{5}{2} \left(\frac{3}{10}\right)^2 \left(\frac{7}{10}\right)^3$$

```
1 dbinom(x = 2, size = 5, prob = 3/10)
2 #0.1029193
```

x : Wie viele Rote Bälle wir bekommen wollen,
 $size$: Wie Oft wir ziehen,
 $prob$: Die prob einen Roten Ball zu ziehen

Hypergemoetric Distribution ohne zurücklegen

⚠️ Wie Binomial, aber ohne Zurücklegen ⚠️

$$P(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$$

N : Gesamtanzahl aller Elemente(z.B alle Kugeln),

M : Anzahl der Roten Kugeln gesamt,

n : Wie oft wir Ziehen,

k : Wie viele Roten wir Ziehen

```
1 dhyper(x = 2, m = 3, n = 7, k = 5)
2 #0.4166667
```

x : wie viele von den gezogenen Bällen Rot sein sollen,
 M : wie viele Rote Bälle,
 n : wie viele nicht Rote,
 k : wie viele Bälle wir ziehen

Multinomial Distribution mit zurücklegen

⚠️ Wie Binomial aber mit mehr als zwei Optionen. ⚠️

Beispiel: Angenommen, wir haben $n = 5$ Versuche. drei mögliche Ergebnisse (z.B. rot, blau, schwarz) mit $Rot = \frac{15}{20}$, $Grün = \frac{4}{20}$, $Blau = \frac{1}{20}$. Wir fragen: Wie groß ist die Wahrscheinlichkeit, dass genau $Rot=2$, $Grün=2$, $Blau=1$ auftritt?

Formel:
$$\frac{n!}{x_1! x_2! \dots x_k!} p_1^{x_1} p_2^{x_2} \dots p_k^{x_k}$$

$$\frac{5!}{2!2!1!} \left(\frac{15}{20}\right)^2 \left(\frac{4}{20}\right)^2 \left(\frac{1}{20}\right)^1 = 0.3375$$

```
1 (factorial(5) / (factorial(2) * factorial(2) *
  factorial(1))) *
2 ((15/20)^2 * (4/20)^2 * (1/20)^1)
3 #0.03375
```

Multivariate Hypergeometric Distribution

OHNE zurücklegen

⚠️ Wie Binomial aber mit mehr als zwei Optionen. ⚠️

Beispiel:

Angenommen, wir haben $n = 5$ Versuche.

drei mögliche Ergebnisse (z.B. rot, blau, schwarz) mit

$Rot = \frac{15}{20}$, $Grün = \frac{4}{20}$, $Blau = \frac{1}{20}$. Wir fragen: Wie groß ist die Wahrscheinlichkeit, dass genau $Rot=2$, $Grün=2$, $Blau=1$ auftritt?

Formel:
$$P(X_1 = k_1, X_2 = k_2, \dots, X_r = k_r) = \frac{\binom{K_1}{k_1} \binom{K_2}{k_2} \dots \binom{K_r}{k_r}}{\binom{N}{n}}$$

$$\frac{\binom{15}{2} \binom{4}{2} \binom{1}{1}}{\binom{20}{5}} \approx 0.04063467$$

```
1 (choose(15,2) * choose(4,2) * choose(1,1)) /
  choose(20,5)
2 #0.04063467
```

Sequentielle Ziehung mit Zurücklegen

⚠️ mit Zurücklegen ⚠️

Wir haben insgesamt 20 Bälle, davon sind 15 Bälle nicht rot und 5 Bälle sind rot. Wir wollen die Wahrscheinlichkeit erst 4 nicht rote Bälle zu ziehen und dann ein roten Ball zu ziehen.

$$P(\text{Keinen roten Ball}) = \frac{15}{20}$$
$$P(\text{Einen roten Ball}) = \frac{5}{20}$$

$$P(X = 5) = \left(1 - \frac{15}{20}\right)^4 \cdot \frac{4}{15}$$

```
1 (1 - (5 / 20))^4 * 5 / 20
```

Sequentielle Ziehung Ohne Zurücklegen

⚠️ Ohne Zurücklegen ⚠️

Wir haben insgesamt 20 Bälle, davon sind 15 Bälle nicht rot und 5 Bälle sind rot. Wir wollen die Wahrscheinlichkeit erst 4 nicht rote Bälle zu ziehen und dann ein roten Ball zu ziehen.

$$P(\text{Keinen roten Ball}) = \frac{15}{20}$$
$$P(\text{Einen roten Ball}) = \frac{5}{20}$$
$$P(\text{einen roten Ball nach 4 Zügen}) = \frac{5}{16}$$

$$P(X = 5) = \frac{\binom{15}{4} \binom{5}{1}}{\binom{20}{5}} \cdot \frac{5}{16}$$

Wir berechnen die Wahrscheinlichkeit 4 nicht rote Bälle zu ziehen Multipliziert mit der Wahrscheinlichkeit einen roten aus den verbleibenden Bällen zu Ziehen.

```
1 ((choose(15,4)*choose(5,0))/choose(20,4)
  ) * 5/16
```

2 Type I and II Errors

Statistical decision	True state of H_0	
	H_0 True	H_0 False
Reject H_0	Type I Error	Correct
Do not reject H_0	Correct	Type II Error

Definitions:

- α : Probability of rejecting H_0 given that H_0 is true.
- β : Probability of not rejecting H_0 given that H_0 is false.

3 Relevante Übersetzungen

1. Dispersion: Streuung (vermutlich SD gemeint)
2. Scatter: Streuung (vermutlich SD gemeint)

4 P-Value

Hypothese	Test-Typ	p-Wert Berechnung
$H_0 : \mu \geq \mu_0$	Einseitig (links)	$p = \text{pnorm}(z)$
$H_0 : \mu \leq \mu_0$	Einseitig (rechts)	$p = 1 - \text{pnorm}(z)$
$H_0 : \mu = \mu_0$	Zweiseitig	$p = 2 \cdot \text{pnorm}(- z)$

5 Library

library(TeachingDemos)

- Der Index 0 z.B. μ_0 bedeutet, dass es sich um einen gegebenen Wert, und nicht um einen geschätzten Wert handelt.

I) Gauß Test:

Hauptziel: Hier wird die Hypothese über den Mittelwert (μ) getestet

Mean μ ist unbekannt, wir kennen SD σ

Gegeben muss sein:

$$H_0: \mu = \mu_0, \quad H_0: \mu \leq \mu_0, \quad H_0: \mu \geq \mu_0$$

Symbol	Bedeutung
n	Stichprobengröße
σ_0	Standardabweichung der Gesamtheit
$\bar{X}_{(n)}$	Sample Mean

Decision Rule R:

$$T = \frac{\bar{X} - \mu_0}{\frac{\sigma_0}{\sqrt{n}}} \in R \implies \text{reject } H_0$$

Rejection Region R:

H_0	rejection region R
$\mu = \mu_0$	$(-\infty, -u_{1-\frac{\alpha}{2}}) \cup (u_{1-\frac{\alpha}{2}}, \infty)$
$\mu \leq \mu_0$	$(u_{1-\alpha}, \infty)$
$\mu \geq \mu_0$	$(-\infty, -u_{1-\alpha})$

$$u_{1-\frac{\alpha}{2}} = \text{qnorm}(1 - (\alpha / 2))$$

Beispiel:

```

1 n <- 100
2 sd <- 0.3
3 sample_mean <- 10.1
4 alpha <- 0.1
5 #H0: mu = 10, H1: mu != 10
6 mu0 <- 10
7 #Rejection region
8 ru <- qnorm(1 - (alpha / 2))
9 rl <- -qnorm(1 - (alpha / 2))
10 #[-1.644854, 1.644854]
11 #teststatistic
12 t <- (sample_mean - mu0) / (sd / sqrt(n))
13 #3.333333
14 t > ru
15 #True
16 #we reject h0 because we are in the
    rejection region
17 p_value <- 2* pnorm(-abs(t))
18 #0.0008581207
19 p_value < alpha
20 #True we reject H0

```

hier vielleicht noch z test einfügen

II) t-Test:

Hauptziel: Hier wird die Hypothese über den Mittelwert (μ) getestet.

Mean μ und SD σ_0 sind unbekannt

△ Mean μ_0 wird durch H_0 gegeben △

Gegeben muss sein:

$$H_0: \mu = \mu_0, \quad H_0: \mu \leq \mu_0, \quad H_0: \mu \geq \mu_0$$

Symbol	Bedeutung
n	Stichprobengröße
$S_{(n)}$	Sample SD
$\bar{X}_{(n)}$	Sample Mean

Decision Rule:

$$T = \frac{\bar{X} - \mu_0}{\frac{S_{(n)}}{\sqrt{n}}} \in R \implies \text{reject } H_0$$

Rejection Region R:

H_0	Rejection Region R
$\mu = \mu_0$	$(-\infty, -t_{n-1, 1-\frac{\alpha}{2}}) \cup (t_{n-1, 1-\frac{\alpha}{2}}, \infty)$
$\mu \leq \mu_0$	$(t_{n-1, 1-\alpha}, \infty)$
$\mu \geq \mu_0$	$(-\infty, -t_{n-1, 1-\alpha})$

$$t_{n-1, 1-\frac{\alpha}{2}} = \text{qt}(1-\alpha, n-1)$$

Beispiel:

```

1 #H0: mu >= 250, h1: < 250
2 n <- 82
3 sample_mu <- 248
4 sample_sd <- 5
5 alpha <- 0.05
6 mu0 <- 250
7 R <- -qt(1-alpha, n-1)
8 #[ , -1.663884]
9 t <- (sample_mu - mu0) / ((sample_sd) /
    sqrt(n))
10 #-3.622154
11 t < R
12 #We reject the H0
13 p_value <- pt(t, n - 1)
14 #0.0002540167
15 p_value < alpha
16 #True We reject the H0

```

III) Test für Varianz σ_0^2 :

Hauptziel: Hier wird die Hypothese über die Varianz (σ_0^2) getestet.

Mean μ und SD σ sind unbekannt

⚠ Kein σ_0 da σ gegeben durch H_0 ⚠

⚠ Also kein Schätzwert ⚠

Gegeben muss sein:

$$H_0: \sigma^2 = \sigma_0^2, \quad H_0: \sigma^2 \leq \sigma_0^2, \quad H_0: \sigma^2 \geq \sigma_0^2$$

Symbol	Bedeutung
$S_{(n)}^2$	Sample SD
$\bar{X}_{(n)}$	Sample Mean

Decision Rule:

$$T = \frac{(n-1) S_{(n)}^2}{\sigma_0^2} \in R \implies \text{reject } H_0.$$

Rejection Region R:

H_0	rejection region R
$\sigma^2 = \sigma_0^2$	$(0, \chi_{n-1, \frac{\alpha}{2}}^2) \cup (\chi_{n-1, 1-\frac{\alpha}{2}}^2, \infty)$
$\sigma^2 \leq \sigma_0^2$	$(\chi_{n-1, 1-\alpha}^2, \infty)$
$\sigma^2 \geq \sigma_0^2$	$(0, \chi_{n-1, \alpha}^2)$

Beispiel:

```
1 #h0: sd >= 7, h1: sd < 7
2 n <- 82
3 sample_mu <- 248
4 sample_sd <- 5
5 alpha <- 0.05
6 sd0 <- 7
7 #Rejection region
8 R <- qchisq(alpha, n-1)
9 #[ , 61.26148
10 #Teststatistics
11 t <- ((n - 1) * sample_sd)/sd0
12 #57.85714
13 t < R
14 #We reject H0, in R area
15 p_value <- pchisq(t, n-1)
16 #0.02419782
17 p_value < alpha
18 #we reject H0
```

III) Bernoulli Test für Probability p_0 :

Hauptziel: Zu prüfen, ob die beobachtete Erfolgsrate \hat{p} signifikant von der vorgegebenen Wahrscheinlichkeit p_0 abweicht

Probability p_0 ist unbekannt

Number of successes: $X = \sum_{i=1}^n X_i \sim B(n, p)$, d.h. $\mathbb{E}(X) = np$

$$\text{Var}(X) = np(1-p).$$

Gegeben muss sein:

$$H_0: p = p_0, \quad H_0: p \leq p_0, \quad H_0: p \geq p_0$$

Symbol	Bedeutung
n	Stichprobengröße
X	Number of successes
\hat{p}	$\frac{X}{n}$ Example Probability

Teststatistic

$$T = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}, \quad \text{mit } \hat{p} = \frac{X}{n}.$$

Rejection Region R

H_0	Rejection Area R
$p = p_0$	$(-\infty, -u_{1-\frac{\alpha}{2}}) \cup (u_{1-\frac{\alpha}{2}}, \infty)$
$p \leq p_0$	$(u_{1-\alpha}, \infty)$
$p \geq p_0$	$(-\infty, -u_{1-\alpha})$

Normal Approximation:

```
1 #a) 80% immunity rate
2 #b) H0: p <= 80, H1: p > 80
3 p0 <- 0.8; n <- 200; x <- 172
4 alpha <- 0.05
5 phut <- x / n
6 #Rejection region
7 R <- pnorm(1 - alpha)
8 #r <- [0.8289439, ]
9 #teststatistic
10 t <- (phut-p0)/sqrt((p0 * (1 - p0)) / n)
11 #2.12132
12 t > R
13 #We reject H0
14 p_value <- 1 - pnorm(t)
15 #0.01694743
16 p_value < alpha
17 #We reject H0
```

Exact test:

```
1 #exact
2 binom.test(172, p = 0.8, n = n,
             alternative = 'greater', conf.level =
               1-alpha)
3 #0.01793
```

0) Alle Infos 2-Sample Tests:

I) 2-Sample Gauss Test:

Hauptziel: Hier wird die Hypothese über die Mittelwerte (μ_1, μ_2) getestet

Means sind unbekannt, wir kennen σ_1, σ_2

Gegeben muss sein:

$$H_0: \mu_1 = \mu_2, \quad H_0: \mu_1 \leq \mu_2, \quad H_0: \mu_1 \geq \mu_2$$

Symbol	Bedeutung
n_1, n_2	Stichprobengrößen
σ_1, σ_2	SD der gesamtheiten
$\bar{X}_{(n_1)}, \bar{Y}_{(n_2)}$	Sample Means

Teststatistik:

$$T = \frac{\bar{X}_{(n_1)} - \bar{Y}_{(n_2)}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

Decision Rule R:

$$T \in R \implies \text{reject } H_0$$

Rejection Region R:

H_0	Rejection Region R
$\mu_1 = \mu_2$	$(-\infty, -u_{1-\frac{\alpha}{2}}) \cup (u_{1-\frac{\alpha}{2}}, \infty)$
$\mu_1 \leq \mu_2$	$(u_{1-\alpha}, \infty)$
$\mu_1 \geq \mu_2$	$(-\infty, u_\alpha)$

Beispiel:

```
1 m1 <- c(5.46, 5.34, ..., 5.82)
2 m2 <- c(5.45, 5.31, 4.11, ..., 4.09)
3 sd1 <- 0.5
4 sd2 <- 0.6
5 n1 <- length(m1)
6 n2 <- length(m2)
7 #test the H0: mu1 >= mu2
8 alpha <- 0.05
9 #rejection Region
10 r <- qnorm(alpha)
11 #[ , -1.644854]
12 #teststistic
13 t <- (mean(m1) - mean(m2)) /
14     sqrt((sd1^2 / n1) + (sd2^2 / n2))
15 #1.027782
16 p_value <- pnorm(t)
17 #0.8479739
18 #we fail to reject H0 since we are
    outside of the rejection area
```

II) 2-Sample t-Test (Varianzen gleich und unbekannt):

Hauptziel: Hier wird die Hypothese über die Mittelwerte (μ_1, μ_2) getestet

Means μ_1, μ_2 sind unbekannt und $\sigma_1 = \sigma_2$

Gegeben muss sein:

$$H_0: \mu_1 = \mu_2, \quad H_0: \mu_1 \leq \mu_2, \quad H_0: \mu_1 \geq \mu_2$$

⚠ Es muss für x und y ein Sample gegeben sein ⚠

Beispiel:

```
1 x <- c(7.06, 11.84, ..., 8.54)
2 y <- c(8.68, 6, 7.82, 4.7, ..., 12.36)
3 #H0: X >= Y, H1 x < y
4 #####
5 #case: equal variances:
6
7 t.test(x, y, alternative = 'less',
8       paired = F, var.equal = T, conf.level
9       = 0.95)
10 #p-value = 0.0181
11 #we can reject the h0 since we are under
12 0.05
```

III) Welch test (Varianzen ungleich, aber unbekannt):

Hauptziel: Hier wird die Hypothese über die Mittelwerte (μ_1, μ_2) getestet

Means μ_1, μ_2 sind unbekannt und $\sigma_1 \neq \sigma_2$

Gegeben muss sein:

$$H_0: \mu_1 = \mu_2, \quad H_0: \mu_1 \leq \mu_2, \quad H_0: \mu_1 \geq \mu_2$$

⚠ Es muss für x und y ein Sample gegeben sein ⚠

Beispiel:

```
1 x <- c(7.06, 11.84, ..., 8.54)
2 y <- c(8.68, 6, 7.82, 4.7, ..., 12.36)
3 #H0: X >= Y, H1 x < y
4 #####
5 #case: unequal variances:
6
7 t.test(x, y, alternative = 'less',
8       paired = F, var.equal = F, conf.level
9       = 0.95)
10 #p-value = 0.01596
11 #we can reject the h0 since we are under
12 0.05
```

⚠ Das einzige was sich ändert ist: var.equal = F ⚠

IV) Two Paired Sample t-Test

⚠ Wenn Z.B einzelne Partienten vorher nacher ⚠
Hauptziel: Wir berechnen als erstes den Unterschied aller Werte der beiden Samples, und dann schauen ob der Mean signifikant Unterschiedlich von 0 ist.

σ ist unbekannt

Gegeben muss sein:

$$H_0: \mu_1 = 0, \quad H_0: \mu_1 \leq 0, \quad H_0: \mu_1 \geq 0$$

⚠ Es muss für x und y ein Sample gegeben sein ⚠

Beispiel:

```
1 #H0: mu = 0, H1: mu != 0
2 x <- c(16, 15, 11, 20, ..., 15, 14, 16)
3 y <- c(13, 13, 10, ..., 10, 15, 11, 16)
4 t.test(x = x, y = y, alternative = 'two.
5       sided', paired = T, var.equal = T,
6       conf.level = 0.95, mu = 0)
7 #0.0007205
```

⚠ Das einzige was sich ändert ist: paired = T ⚠

V) Testing two Variances - F Test

Hauptziel: Wir vergleichen die beiden sample Varianzen.

σ ist unbekannt

Gegeben muss sein:

$$H_0: \sigma_1 = \sigma_2, \quad H_0: \sigma_1 \leq \sigma_2, \quad H_0: \sigma_1 \geq \sigma_2$$

⚠ Es muss für x und y ein Sample gegeben sein ⚠

Beispiel:

```
1 x <- c(102.4, 101.3, ..., 100.1)
2 y <- c(98.4, 101.7, ..., 101.0)
3 #H0: sd_x <= sd_y, H1: sd_x > sd_y
4 alpha <- 0.05
5 var.test(x = x, y = y, alternative = '
6       greater', conf.level = 1-alpha)
7 #p-value = 0.03404
```

Beispiel: Erst H0 dass vars gleich sind. Wenn nicht reject, dann müssten wir mein Mean test, var.equal auf True

```
1 #H0: sigma_x = sigma_y, H1: sigma_x != sigma_y
2 var.test(x = x, y = y, alternative = 'two.sided
3       ', conf.level = 1-alpha)
4 #p-value = 0.8814
5 #we fail to reject H0, also Varianz gleich oder
6       fast gleich
7 #####
8 #H0: mu_x <= mu_y, H1: mu_x > mu_y
9 alpha <- 0.025
10 t.test(x = x, y = y, alternative = 'greater',
11       paired = F, var.equal = TRUE, conf.level =
12       1-alpha)
13 #p-value = 0.02374
14 #we reject H0
```

Wenn